

“リアルな”遅延を測る仕様

Responsiveness under Working Conditions

CDN自作(Y4)ゼミ チューター 八谷航太

より良いサービス体験を提供するために遅延は大事

- 近年、アクセス回線において帯域が問題になることは大きく減った
 - Webページロード、動画再生、ビデオ会議など一般的なワークロードは今の帯域幅(<1Gbps)で問題なく動く
 - 無線規格の帯域幅増加、リクエスト多重化 etc.
- QoEを上げるために、パケットの**伝送遅延**が大きな要素になっている



← こういう時代は終わった

混雑時の遅延が重要


- あるパケットの平常時の伝送遅延は、**サーバーとの距離・経路やキャッシュの有無**が大きな影響を及ぼす
- 混雑時の伝送遅延には**ネットワーク機器のキューイング**が関わってくる
 - Bufferbloat
 - 帯域の太さに関わらずキューイングは発生する
- 任意のネットワーク性能検証サービス（speedtest.com, fast.com etc.）はそのタイミングのスループット、RTTしか示さない
 - fast.comでRTT20msだからこのネットワークは速い！→諸説

混雑時の伝送遅延を測るにはどうすれば??

Responsiveness under Working Conditions

<https://datatracker.ietf.org/doc/draft-ietf-ippm-responsiveness/>

- 回線に十分な負荷をかけ、実際に通信している最中の遅延を測定する
- 新規接続と既存接続の両方で、小さなHTTPリクエストの応答時間を測る
- 測定結果を **RPM** (Round-trips Per Minute) として表現する
 - RTTの逆数
 - 高いほど応答性がよい
- HTTP1/2でテスト



Responsiveness under Working Conditions

- 十分に大きい”infinitely large files”を転送するセッションを張る
- goodputが増加し続けるかに関わらず上限16として徐々にセッション数を増やしていく
- その中で二つの遅延計測セッションを張る
 - Foreign Probe
 - TCP+TLSハンドシェイク
 - HTTPの1バイトのGETリクエストとレスポンス
 - Self Probe
 - 上のInfinitely large filesのセッションで別ストリームとしてGETリクエスト/レスポンス

- 負荷がかかっているネットワークの伝送遅延を測る共通の方法がなかった
- pingより”リアル”な遅延を測る方法が確立されつつある